

Modelos Estadísticos para la Predicción

Derivaciones Analíticas y Demostraciones Paso a Paso

Víctor Aceña (DSLAB)

Documento complementario exhaustivo para las transparencias de clase

Código Cromático de Seguimiento en las Ecuaciones:

- **Púrpura**: Términos objeto de sustitución algebraica directa desde una ecuación previa.
- **Verde/Teal**: Factores fijos del predictor X , pesos muestrales o sumas centradas (S_{xx}).
- **Azul**: Términos vinculados a la variable dependiente Y o componentes explicados sistemáticos.
- **Naranja**: Componentes del error estocástico ε , residuos o sumas que se cancelan ($\rightarrow 0$).

Índice general

1	Tema 1: El modelo de regresión lineal simple	2
1.1	Notación, definiciones y álgebra de sumatorios	2
1.2	Derivación analítica de los estimadores de MCO	3
1.3	Propiedades de predicciones y residuos muestrales	5
1.4	Propiedades de Gauss-Márkov y demostración de varianza mínima (BLUE)	7
1.5	Insensatez de la varianza residual: demostración de $\mathbb{E}[\text{SSE}] = (n - 2)\sigma^2$	9
1.6	Descomposición de la variabilidad (ANOVA) y demostración de $R^2 = r^2$	11
1.7	Inferencia bajo normalidad y equivalencia exacta: test t vs. test F	11
1.8	Inferencia predictiva: respuesta media vs. nueva observación	12
1.9	Diagnóstico e influencia: matriz H , Sherman-Morrison, Cook y DFFITS	13
2	Tema 2: El modelo de regresión lineal múltiple	17
2.1	Propiedades estadísticas de MCO en regresión múltiple	18
2.2	Teorema de Gauss-Márkov y varianza mínima (BLUE)	19
2.3	Insensatez de la varianza residual matricial	19

1. Tema 1: El modelo de regresión lineal simple

1.1 Notación, definiciones y álgebra de sumatorios

Sea $\{(x_i, y_i)\}_{i=1}^n$ una muestra observada de tamaño n . Definimos las medias muestrales como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \quad (1)$$

y las cantidades asociadas a la dispersión muestral:

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2 \quad (2)$$

$$S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad (3)$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} \quad (4)$$

Lema 1: propiedades fundamentales de centrado

Sean $\{a_i\}_{i=1}^n$ y $\{b_i\}_{i=1}^n$ constantes reales arbitrarias con medias aritméticas $\bar{a} = \frac{1}{n} \sum a_i$ y $\bar{b} = \frac{1}{n} \sum b_i$.

1. Demostración de $\sum_{i=1}^n (a_i - \bar{a}) = 0$:

$$\sum_{i=1}^n (a_i - \bar{a}) = (a_1 - \bar{a}) + (a_2 - \bar{a}) + \cdots + (a_n - \bar{a}) \quad (5)$$

$$= \sum_{i=1}^n a_i - \sum_{i=1}^n \bar{a} \quad (6)$$

$$= \sum_{i=1}^n a_i - n\bar{a} \quad (7)$$

$$= n \left(\frac{1}{n} \sum_{i=1}^n a_i \right) - n\bar{a} \quad (8)$$

$$= n\bar{a} - n\bar{a} = 0. \quad (9)$$

2. Demostración de $\sum_{i=1}^n (a_i - \bar{a})b_i = \sum_{i=1}^n (a_i - \bar{a})(b_i - \bar{b})$: Desarrollamos el término derecho de la igualdad distribuyendo el producto:

$$\sum_{i=1}^n (a_i - \bar{a})(b_i - \bar{b}) = \sum_{i=1}^n \left((a_i - \bar{a})b_i - (a_i - \bar{a})\bar{b} \right) \quad (10)$$

$$= \sum_{i=1}^n (a_i - \bar{a})b_i - \sum_{i=1}^n (a_i - \bar{a})\bar{b} \quad (11)$$

$$= \sum_{i=1}^n (a_i - \bar{a})b_i - \bar{b} \underbrace{\sum_{i=1}^n (a_i - \bar{a})}_{=0 \text{ por el Paso 1}} \quad (12)$$

$$= \sum_{i=1}^n (a_i - \bar{a})b_i - \bar{b} \cdot 0 \quad (13)$$

$$= \sum_{i=1}^n (a_i - \bar{a})b_i. \quad (14)$$

Por simetría, intercambiando los roles de las variables a y b :

$$\sum_{i=1}^n a_i(b_i - \bar{b}) = \sum_{i=1}^n (a_i - \bar{a})(b_i - \bar{b}). \quad (15)$$

1.2 Derivación analítica de los estimadores de MCO

La función objetivo que buscamos minimizar respecto a β_0 y β_1 es la suma de los residuos al cuadrado:

$$\text{SSE}(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (16)$$

Condiciones de primer orden y despeje analítico de $\hat{\beta}_0$ y $\hat{\beta}_1$

Paso 1: Cálculo de las derivadas parciales mediante la regla de la cadena:

$$\frac{\partial \text{SSE}}{\partial \beta_0} = \frac{\partial}{\partial \beta_0} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (17)$$

$$= \sum_{i=1}^n \frac{\partial}{\partial \beta_0} (y_i - \beta_0 - \beta_1 x_i)^2 \quad (18)$$

$$= \sum_{i=1}^n 2(y_i - \beta_0 - \beta_1 x_i) \cdot \frac{\partial}{\partial \beta_0} (y_i - \beta_0 - \beta_1 x_i) \quad (19)$$

$$= \sum_{i=1}^n 2(y_i - \beta_0 - \beta_1 x_i) \cdot (-1) \quad (20)$$

$$= -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (21)$$

$$\frac{\partial \text{SSE}}{\partial \beta_1} = \frac{\partial}{\partial \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (22)$$

$$= \sum_{i=1}^n 2(y_i - \beta_0 - \beta_1 x_i) \cdot \frac{\partial}{\partial \beta_1} (y_i - \beta_0 - \beta_1 x_i) \quad (23)$$

$$= \sum_{i=1}^n 2(y_i - \beta_0 - \beta_1 x_i) \cdot (-x_i) \quad (24)$$

$$= -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (25)$$

Paso 2: Despeje riguroso del estimador $\hat{\beta}_0$: Dividimos ambos miembros de la ecuación (21) entre -2 :

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (26)$$

Distribuimos el sumatorio a cada uno de los sumandos:

$$\sum_{i=1}^n y_i - \sum_{i=1}^n \beta_0 - \beta_1 \sum_{i=1}^n x_i = 0. \quad (27)$$

Dado que $\sum_{i=1}^n \beta_0 = n\beta_0$:

$$\sum_{i=1}^n y_i - n\beta_0 - \beta_1 \sum_{i=1}^n x_i = 0. \quad (28)$$

Dividimos todos los t́rminos entre el tamao muestral n :

$$\frac{1}{n} \sum_{i=1}^n y_i - \frac{n\beta_0}{n} - \beta_1 \left(\frac{1}{n} \sum_{i=1}^n x_i \right) = 0. \quad (29)$$

Reconociendo las medias muestrales $\bar{y}$ y $\bar{x}$:

$$\bar{y} - \beta_0 - \beta_1 \bar{x} = 0 \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}. \quad (30)$$

Paso 3: Sustituci3n de $\hat{\beta}_0$ en la segunda ecuaci3n (25) para despejar $\hat{\beta}_1$: Dividimos la ecuaci3n (25) entre -2 :

$$\sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (31)$$

Reemplazamos β_0 por la expresi3n obtenida en (30):

$$\sum_{i=1}^n x_i (y_i - (\bar{y} - \beta_1 \bar{x}) - \beta_1 x_i) = 0. \quad (32)$$

Distribuimos el signo negativo interior:

$$\sum_{i=1}^n x_i (y_i - \bar{y} + \beta_1 \bar{x} - \beta_1 x_i) = 0. \quad (33)$$

Agrupamos factorizando β_1 en los t́rminos que contienen el regresor:

$$\sum_{i=1}^n x_i [(y_i - \bar{y}) - \beta_1 (x_i - \bar{x})] = 0. \quad (34)$$

Distribuimos el producto por x_i y separamos los sumatorios:

$$\sum_{i=1}^n x_i (y_i - \bar{y}) - \beta_1 \sum_{i=1}^n x_i (x_i - \bar{x}) = 0. \quad (35)$$

Aplicamos el Lema 1 a ambos t́rminos:

$$\sum_{i=1}^n x_i (y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = S_{xy} \quad (36)$$

$$\sum_{i=1}^n x_i (x_i - \bar{x}) = \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x}) = \sum_{i=1}^n (x_i - \bar{x})^2 = S_{xx} \quad (37)$$

Sustituyendo estas sumas centradas:

$$S_{xy} - \beta_1 S_{xx} = 0 \implies \hat{\beta}_1 S_{xx} = S_{xy} \implies \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (38)$$

Paso 4: Condición de Segundo Orden (Verificación de Mínimo Global): Calculamos la matriz de derivadas segundas (Hessiana):

$$\frac{\partial^2 \text{SSE}}{\partial \beta_0^2} = \frac{\partial}{\partial \beta_0} \left[-2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) \right] = 2 \sum_{i=1}^n 1 = 2n \quad (39)$$

$$\frac{\partial^2 \text{SSE}}{\partial \beta_1^2} = \frac{\partial}{\partial \beta_1} \left[-2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) \right] = 2 \sum_{i=1}^n x_i^2 \quad (40)$$

$$\frac{\partial^2 \text{SSE}}{\partial \beta_0 \partial \beta_1} = \frac{\partial}{\partial \beta_1} \left[-2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) \right] = 2 \sum_{i=1}^n x_i = 2n\bar{x} \quad (41)$$

La matriz Hessiana resulta:

$$\mathbf{H} = \begin{pmatrix} 2n & 2n\bar{x} \\ 2n\bar{x} & 2 \sum_{i=1}^n x_i^2 \end{pmatrix}. \quad (42)$$

Evaluamos los menores principales:

1. $D_1 = 2n > 0$ (puesto que $n \geq 2$).

2. $D_2 = \det(\mathbf{H}) = (2n) \left(2 \sum_{i=1}^n x_i^2 \right) - (2n\bar{x})^2 = 4n \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) = 4n S_{xx}$.

Dado que los puntos en X no son todos idénticos, $S_{xx} = \sum (x_i - \bar{x})^2 > 0$, lo que implica $D_2 > 0$. Al ser ambos menores principales estrictamente positivos, $\mathbf{H}$ es estrictamente definida positiva en todo $\mathbb{R}^2$, confirmando que la solución hallada es el **mínimo global único**.

1.3 Propiedades de predicciones y residuos muestrales

Definimos el valor predicho para el punto i como $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ y el residuo como $e_i = y_i - \hat{y}_i$.

Demostración de las cuatro propiedades algebraicas

Propiedad 1: La recta pasa necesariamente por el centro $(\bar{x}, \bar{y})$ Evaluamos la recta ajustada en el punto medio $x = \bar{x}$:

$$\hat{y}(\bar{x}) = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \quad (43)$$

$$= (\bar{y} - \hat{\beta}_1 \bar{x}) + \hat{\beta}_1 \bar{x} \quad (\text{sustituyendo } \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}) \quad (44)$$

$$= \bar{y} + \underbrace{(-\hat{\beta}_1 \bar{x} + \hat{\beta}_1 \bar{x})}_0 = \bar{y}. \quad (45)$$

Propiedad 2: Suma nula de residuos y coincidencia de medias muestrales De la primera condición de primer orden (21):

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \implies \sum_{i=1}^n (y_i - \hat{y}_i) = 0 \implies \sum_{i=1}^n e_i = 0. \quad (46)$$

Por tanto, la media aritmética de los residuos es idénticamente nula:

$$\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i = \frac{1}{n} \cdot 0 = 0. \quad (47)$$

Como cada observaci3n verifica $y_i = \hat{y}_i + e_i$, sumamos sobre toda la muestra:

$$\sum_{i=1}^n y_i = \sum_{i=1}^n (\hat{y}_i + e_i) = \sum_{i=1}^n \hat{y}_i + \sum_{i=1}^n e_i = \sum_{i=1}^n \hat{y}_i + 0 = \sum_{i=1}^n \hat{y}_i. \quad (48)$$

Dividiendo entre n :

$$\frac{1}{n} \sum_{i=1}^n y_i = \frac{1}{n} \sum_{i=1}^n \hat{y}_i \implies \bar{y} = \bar{\hat{y}}. \quad (49)$$

Propiedad 3: Ortogonalidad e incorrelaci3n muestral entre X y e De la segunda condici3n de primer orden (25):

$$-2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \implies \sum_{i=1}^n x_i (y_i - \hat{y}_i) = 0 \implies \sum_{i=1}^n x_i e_i = 0. \quad (50)$$

Esto demuestra la ortogonalidad vectorial. Calculamos la covarianza muestral:

$$\widehat{\text{Cov}}(x, e) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(e_i - \bar{e}) \quad (51)$$

$$= \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})e_i \quad (\text{dado que } \bar{e} = 0) \quad (52)$$

$$= \frac{1}{n-1} \left(\sum_{i=1}^n x_i e_i - \bar{x} \sum_{i=1}^n e_i \right) \quad (53)$$

$$= \frac{1}{n-1} \left(\sum_{i=1}^n x_i e_i - \bar{x} \sum_{i=1}^n e_i \right) = \frac{0}{n-1} = 0. \quad (54)$$

Propiedad 4: Ortogonalidad e incorrelaci3n entre $\hat{Y}$ y e Multiplicamos el valor predicho por el residuo y sumamos:

$$\sum_{i=1}^n \hat{y}_i e_i = \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_i) e_i = \sum_{i=1}^n (\hat{\beta}_0 e_i + \hat{\beta}_1 x_i e_i) \quad (55)$$

$$= \hat{\beta}_0 \sum_{i=1}^n e_i + \hat{\beta}_1 \sum_{i=1}^n x_i e_i = \hat{\beta}_0(0) + \hat{\beta}_1(0) = 0. \quad (56)$$

Calculamos la covarianza muestral:

$$\widehat{\text{Cov}}(\hat{y}, e) = \frac{1}{n-1} \sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})(e_i - \bar{e}) = \frac{1}{n-1} \sum_{i=1}^n (\hat{y}_i - \bar{y})e_i \quad (57)$$

$$= \frac{1}{n-1} \left(\sum_{i=1}^n \hat{y}_i e_i - \bar{y} \sum_{i=1}^n e_i \right) = \frac{1}{n-1} (0 - 0) = 0. \quad (58)$$

Advertencia Metodológica: Propiedades del álgebra de ajuste vs. supuestos estadísticos

Es un error muy extendido entre los alumnos pensar que $\sum e_i = 0$ o que $\widehat{\text{Cov}}(x, e) = 0$ demuestran que los supuestos del modelo se cumplen.

- Estas cuatro identidades son consecuencias puramente algebraicas de haber igualado las derivadas a cero. Se cumplen en **cualquier conjunto numérico**, incluso si la verdadera relación es no lineal o heterocedástica.
- Si se ajusta un modelo sin intercepto ($Y_i = \beta_1 X_i + \varepsilon_i$), en general $\sum e_i \neq 0$ y $\bar{\hat{y}} \neq \bar{y}$.

1.4 Propiedades de Gauss-Márkov y demostración de varianza mínima (BLUE)

Escribimos la pendiente como combinación lineal de las observaciones:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{S_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{S_{xx}} = \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S_{xx}} \right) Y_i = \sum_{i=1}^n k_i Y_i \quad (59)$$

definiendo los coeficientes escalares fijos $k_i \equiv \frac{x_i - \bar{x}}{S_{xx}}$.

Propiedades de los pesos k_i , insesgadez, varianzas y optimalidad BLUE

Paso 1: Demostración formal de las propiedades algebraicas de k_i :

$$\sum_{i=1}^n k_i = \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) = \frac{1}{S_{xx}} \cdot 0 = 0, \quad (60)$$

$$\sum_{i=1}^n k_i x_i = \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S_{xx}} \right) x_i \stackrel{\text{Lema 1}}{=} \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{S_{xx}}{S_{xx}} = 1, \quad (61)$$

$$\sum_{i=1}^n k_i^2 = \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S_{xx}} \right)^2 = \frac{1}{S_{xx}^2} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{S_{xx}}{S_{xx}^2} = \frac{1}{S_{xx}}. \quad (62)$$

Paso 2: Demostración de insesgadez de $\hat{\beta}_1$ ($\mathbb{E}[\hat{\beta}_1] = \beta_1$):

$$\mathbb{E}[\hat{\beta}_1] = \mathbb{E} \left[\sum_{i=1}^n k_i Y_i \right] = \sum_{i=1}^n k_i \mathbb{E}[Y_i] = \sum_{i=1}^n k_i (\beta_0 + \beta_1 x_i) \quad (63)$$

$$= \beta_0 \sum_{i=1}^n k_i + \beta_1 \sum_{i=1}^n k_i x_i \quad (64)$$

$$= \beta_0 \cdot \sum_{i=1}^n k_i + \beta_1 \cdot \underbrace{\sum_{i=1}^n k_i x_i}_{=1} = \beta_0(0) + \beta_1(1) = \beta_1. \quad (65)$$

Paso 3: Demostración de insesgadez de $\hat{\beta}_0$ ($\mathbb{E}[\hat{\beta}_0] = \beta_0$): Calculamos primero $\mathbb{E}[\bar{Y}]$:

$$\mathbb{E}[\bar{Y}] = \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n Y_i \right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[Y_i] = \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1 x_i) \quad (66)$$

$$= \frac{1}{n} \left(n\beta_0 + \beta_1 \sum_{i=1}^n x_i \right) = \beta_0 + \beta_1 \bar{x}. \quad (67)$$

Por tanto:

$$\mathbb{E}[\hat{\beta}_0] = \mathbb{E}[\bar{Y} - \hat{\beta}_1 \bar{x}] = \mathbb{E}[\bar{Y}] - \bar{x}\mathbb{E}[\hat{\beta}_1] = (\beta_0 + \beta_1 \bar{x}) - \bar{x}\beta_1 = \beta_0. \quad (68)$$

Paso 4: Varianza de la pendiente $\hat{\beta}_1$: Por ser las observaciones condicionalmente independientes con varianza σ^2 :

$$\text{Var}(\hat{\beta}_1) = \text{Var}\left(\sum_{i=1}^n k_i Y_i\right) = \sum_{i=1}^n k_i^2 \text{Var}(Y_i) = \sigma^2 \sum_{i=1}^n k_i^2 \stackrel{(62)}{=} \frac{\sigma^2}{S_{xx}}. \quad (69)$$

Paso 5: Varianza del intercepto $\hat{\beta}_0$ y Covarianza Cruzada: Escribimos $\hat{\beta}_0 = \sum_{i=1}^n \left(\frac{1}{n} - \bar{x}k_i\right) Y_i = \sum_{i=1}^n c_i Y_i$:

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \sum_{i=1}^n \left(\frac{1}{n} - \bar{x}k_i\right)^2 = \sigma^2 \sum_{i=1}^n \left(\frac{1}{n^2} - 2\frac{\bar{x}}{n}k_i + \bar{x}^2 k_i^2\right) \quad (70)$$

$$= \sigma^2 \left(\sum_{i=1}^n \frac{1}{n^2} - \frac{2\bar{x}}{n} \sum_{i=1}^n k_i + \bar{x}^2 \sum_{i=1}^n k_i^2 \right) \quad (71)$$

$$= \sigma^2 \left(\frac{n}{n^2} - 0 + \bar{x}^2 \cdot \frac{1}{S_{xx}} \right) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right). \quad (72)$$

Calculamos la covarianza:

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = \text{Cov}\left(\sum_{i=1}^n c_i Y_i, \sum_{j=1}^n k_j Y_j\right) = \sigma^2 \sum_{i=1}^n c_i k_i = \sigma^2 \sum_{i=1}^n \left(\frac{1}{n} - \bar{x}k_i\right) k_i \quad (73)$$

$$= \sigma^2 \left(\frac{1}{n} \sum_{i=1}^n k_i - \bar{x} \sum_{i=1}^n k_i^2 \right) = \sigma^2 \left(0 - \frac{\bar{x}}{S_{xx}} \right) = -\frac{\bar{x}\sigma^2}{S_{xx}}. \quad (74)$$

Paso 6: Demostración de Varianza Mínima (Teorema de Gauss-Márkov): Sea $\tilde{\beta}_1 = \sum_{i=1}^n c_i Y_i$ cualquier otro estimador lineal insesgado. Definimos los desvíos $d_i \equiv c_i - k_i$, de modo que $c_i = k_i + d_i$. La condición de insesgadez universal $\mathbb{E}[\tilde{\beta}_1] = \beta_1$ exige:

$$\mathbb{E}[\tilde{\beta}_1] = \sum_{i=1}^n (k_i + d_i)(\beta_0 + \beta_1 x_i) \quad (75)$$

$$= \beta_0 \left(\sum_{i=1}^n k_i + \sum_{i=1}^n d_i \right) + \beta_1 \left(\underbrace{\sum_{i=1}^n k_i x_i}_{=1} + \sum_{i=1}^n d_i x_i \right) \quad (76)$$

$$= \beta_0 \sum_{i=1}^n d_i + \beta_1 \left(1 + \sum_{i=1}^n d_i x_i \right) \equiv \beta_1. \quad (77)$$

Para que esto se cumpla para cualquier valor poblacional de β_0 y β_1 , es obligatorio que:

$$\sum_{i=1}^n d_i = 0 \quad \text{y} \quad \sum_{i=1}^n d_i x_i = 0. \quad (78)$$

Calculamos ahora la varianza de $\tilde{\beta}_1$:

$$\text{Var}(\tilde{\beta}_1) = \sigma^2 \sum_{i=1}^n c_i^2 = \sigma^2 \sum_{i=1}^n (k_i + d_i)^2 \quad (79)$$

$$= \sigma^2 \sum_{i=1}^n k_i^2 + \sigma^2 \sum_{i=1}^n d_i^2 + 2\sigma^2 \sum_{i=1}^n k_i d_i. \quad (80)$$

Evaluamos el sumatorio del producto cruzado:

$$\sum_{i=1}^n k_i d_i = \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S_{xx}} \right) d_i = \frac{1}{S_{xx}} \left(\sum_{i=1}^n x_i d_i - \bar{x} \sum_{i=1}^n d_i \right) \quad (81)$$

$$= \frac{1}{S_{xx}} \left(\sum_{i=1}^n \cancel{x_i d_i}^0 - \bar{x} \sum_{i=1}^n \cancel{d_i}^0 \right) = \frac{1}{S_{xx}} (0 - 0) = 0. \quad (82)$$

Al anularse el término cruzado, obtenemos:

$$\text{Var}(\tilde{\beta}_1) = \text{Var}(\hat{\beta}_1) + \underbrace{\sigma^2 \sum_{i=1}^n d_i^2}_{\geq 0} \geq \text{Var}(\hat{\beta}_1). \quad (83)$$

La igualdad se alcanza si y solo si $d_i = 0 \forall i \iff c_i = k_i$. Por tanto, $\hat{\beta}_1$ es el **Mejor Estimador Lineal Inssegado (MELI / BLUE)**.

1.5 Inssegadez de la varianza residual: demostración de $\mathbb{E}[\text{SSE}] = (n-2)\sigma^2$

Deducción exhaustiva término a término del denominador $n-2$

Partimos de la relación muestral: $\text{SSE} = S_{yy} - \hat{\beta}_1^2 S_{xx}$. Tomamos esperanzas:

$$\mathbb{E}[\text{SSE}] = \mathbb{E}[S_{yy}] - S_{xx} \mathbb{E}[\hat{\beta}_1^2]. \quad (84)$$

Paso 1: Cálculo exacto de $S_{xx} \mathbb{E}[\hat{\beta}_1^2]$: Por la definición fundamental de varianza: $\mathbb{E}[\hat{\beta}_1^2] = \text{Var}(\hat{\beta}_1) + (\mathbb{E}[\hat{\beta}_1])^2 = \frac{\sigma^2}{S_{xx}} + \beta_1^2$. Multiplicando por S_{xx} :

$$S_{xx} \mathbb{E}[\hat{\beta}_1^2] = S_{xx} \left(\frac{\sigma^2}{S_{xx}} + \beta_1^2 \right) = \sigma^2 + \beta_1^2 S_{xx}. \quad (85)$$

Paso 2: Cálculo exhaustivo término a término de $\mathbb{E}[S_{yy}]$: Como $Y_i - \bar{Y} = \beta_1(x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon})$:

$$(Y_i - \bar{Y})^2 = \left(\beta_1(x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon}) \right)^2 \quad (86)$$

$$= \beta_1^2(x_i - \bar{x})^2 + (\varepsilon_i - \bar{\varepsilon})^2 + 2\beta_1(x_i - \bar{x})(\varepsilon_i - \bar{\varepsilon}). \quad (87)$$

Sumando sobre todas las observaciones $i = 1, \dots, n$:

$$S_{yy} = \beta_1^2 S_{xx} + \sum_{i=1}^n (\varepsilon_i - \bar{\varepsilon})^2 + 2\beta_1 \sum_{i=1}^n (x_i - \bar{x}) \varepsilon_i. \quad (88)$$

Desarrollamos el sumatorio de los errores cuadráticos centrados:

$$\sum_{i=1}^n (\varepsilon_i - \bar{\varepsilon})^2 = \sum_{i=1}^n (\varepsilon_i^2 - 2\varepsilon_i\bar{\varepsilon} + \bar{\varepsilon}^2) \quad (89)$$

$$= \sum_{i=1}^n \varepsilon_i^2 - 2\bar{\varepsilon} \sum_{i=1}^n \varepsilon_i + \sum_{i=1}^n \bar{\varepsilon}^2 \quad (90)$$

$$= \sum_{i=1}^n \varepsilon_i^2 - 2\bar{\varepsilon}(n\bar{\varepsilon}) + n\bar{\varepsilon}^2 \quad (91)$$

$$= \sum_{i=1}^n \varepsilon_i^2 - 2n\bar{\varepsilon}^2 + n\bar{\varepsilon}^2 \quad (92)$$

$$= \sum_{i=1}^n \varepsilon_i^2 - n\bar{\varepsilon}^2. \quad (93)$$

Tomamos ahora la esperanza matemática de cada uno de sus términos:

1. Como $\mathbb{E}[\varepsilon_i] = 0$ y $\text{Var}(\varepsilon_i) = \sigma^2$, tenemos $\mathbb{E}[\varepsilon_i^2] = \sigma^2$. Por consiguiente:

$$\mathbb{E}\left[\sum_{i=1}^n \varepsilon_i^2\right] = \sum_{i=1}^n \mathbb{E}[\varepsilon_i^2] = \sum_{i=1}^n \sigma^2 = n\sigma^2. \quad (94)$$

2. Para la media de los errores $\bar{\varepsilon} = \frac{1}{n} \sum \varepsilon_i$, sabemos que $\mathbb{E}[\bar{\varepsilon}] = 0$ y $\text{Var}(\bar{\varepsilon}) = \frac{\sigma^2}{n}$. Por consiguiente:

$$\mathbb{E}[\bar{\varepsilon}^2] = \text{Var}(\bar{\varepsilon}) + (\mathbb{E}[\bar{\varepsilon}])^2 = \frac{\sigma^2}{n} + 0 = \frac{\sigma^2}{n}. \quad (95)$$

Multiplicando por n :

$$\mathbb{E}[n\bar{\varepsilon}^2] = n \left(\frac{\sigma^2}{n} \right) = \sigma^2. \quad (96)$$

Restando ambas esperanzas obtenemos formalmente:

$$\mathbb{E}\left[\sum_{i=1}^n (\varepsilon_i - \bar{\varepsilon})^2\right] = n\sigma^2 - \sigma^2 = (n-1)\sigma^2. \quad (97)$$

Finalmente, como $\mathbb{E}[\varepsilon_i] = 0$:

$$\mathbb{E}\left[2\beta_1 \sum_{i=1}^n (x_i - \bar{x})\varepsilon_i\right] = 2\beta_1 \sum_{i=1}^n (x_i - \bar{x}) \cancel{\mathbb{E}[\varepsilon_i]}^0 = 0. \quad (98)$$

Uniendo los tres términos:

$$\mathbb{E}[S_{yy}] = \beta_1^2 S_{xx} + (n-1)\sigma^2. \quad (99)$$

Paso 3: Resta algebraica final en (84):

$$\mathbb{E}[\text{SSE}] = \left[\beta_1^2 S_{xx} + (n-1)\sigma^2 \right] - \left[\sigma^2 + \beta_1^2 S_{xx} \right] \quad (100)$$

$$= \cancel{\beta_1^2 S_{xx}} + (n-1)\sigma^2 - \sigma^2 - \cancel{\beta_1^2 S_{xx}} \quad (101)$$

$$= (n-1)\sigma^2 - \sigma^2 = (n-2)\sigma^2. \quad (102)$$

Dividiendo entre $n-2$:

$$\mathbb{E}[\text{MSE}] = \mathbb{E}\left[\frac{\text{SSE}}{n-2}\right] = \frac{(n-2)\sigma^2}{n-2} = \sigma^2. \quad (103)$$

1.6 Descomposición de la variabilidad (ANOVA) y demostración de $R^2 = r^2$ **Demostración de $SST = SSR + SSE$ y $R^2 = r^2$** **Paso 1: Descomposición ortogonal de la suma total:**

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n [(\hat{y}_i - \bar{y}) + e_i]^2 \quad (104)$$

$$= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n e_i^2 + 2 \sum_{i=1}^n (\hat{y}_i - \bar{y}) e_i. \quad (105)$$

El producto cruzado se anula idénticamente por las propiedades muestrales demostradas:

$$\sum_{i=1}^n (\hat{y}_i - \bar{y}) e_i = \sum_{i=1}^n \hat{y}_i e_i - \bar{y} \sum_{i=1}^n e_i = 0 - 0 = 0. \quad (106)$$

Por tanto, se cumple exactamente el Teorema de Pitágoras muestral:

$$SST = SSR + SSE. \quad (107)$$

Paso 2: Deducción de $R^2 = r^2$: Puesto que $\hat{y}_i - \bar{y} = \hat{\beta}_1(x_i - \bar{x})$, tenemos:

$$SSR = \sum_{i=1}^n \hat{\beta}_1^2 (x_i - \bar{x})^2 = \hat{\beta}_1^2 S_{xx} = \left(\frac{S_{xy}}{S_{xx}} \right)^2 S_{xx} = \frac{S_{xy}^2}{S_{xx}}. \quad (108)$$

Sustituyendo en la definición del coeficiente de determinación:

$$R^2 = \frac{SSR}{SST} = \frac{S_{xy}^2 / S_{xx}}{S_{yy}} = \frac{S_{xy}^2}{S_{xx} S_{yy}} = \left(\frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}} \right)^2. \quad (109)$$

Como la correlación lineal muestral de Pearson es $r = \frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}}$, concluimos:

$$R^2 = r^2. \quad (110)$$

1.7 Inferencia bajo normalidad y equivalencia exacta: test t vs. test F **Derivación del estadístico t y prueba de que $t^2 = F$** **Paso 1: Distribución del estimador $\hat{\beta}_1$ y tipificación:** Bajo el supuesto de normalidad $\varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$, al ser $\hat{\beta}_1$ una combinación lineal de variables gaussianas:

$$\hat{\beta}_1 \sim \mathcal{N}\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right) \implies Z = \frac{\hat{\beta}_1 - \beta_1}{\sigma / \sqrt{S_{xx}}} \sim \mathcal{N}(0, 1). \quad (111)$$

Paso 2: Distribución de SSE e Independencia Estocástica: Por el Teorema de Cochran aplicado a la matriz de proyección simétrica e idempotente $(\mathbf{I} - \mathbf{H})$ de rango $n - 2$:

$$U = \frac{SSE}{\sigma^2} \sim \chi_{n-2}^2. \quad (112)$$

Además, como $\text{Cov}(\hat{\beta}_1, e) = \mathbf{0}$, $\hat{\beta}_1$ y SSE son variables aleatorias gaussianas incorreladas y, por tanto, **estocásticamente independientes**.

Paso 3: Construcción del estadístico t de Student: Por definición matemática, el cociente entre una Normal(0,1) y la raíz cuadrada de una Chi-cuadrado independiente dividida por sus grados de libertad sigue una t de Student:

$$T = \frac{Z}{\sqrt{U/(n-2)}} = \frac{\frac{\hat{\beta}_1 - \beta_1}{\sigma/\sqrt{S_{xx}}}}{\sqrt{\frac{\text{SSE}/\sigma^2}{n-2}}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\text{MSE}}{S_{xx}}}} = \frac{\hat{\beta}_1 - \beta_1}{\text{SE}(\hat{\beta}_1)} \sim t_{n-2}. \quad (113)$$

Paso 4: Demostración de $t^2 = F$ para contrastar $H_0 : \beta_1 = 0$: Bajo H_0 , el estadístico t es $t = \frac{\hat{\beta}_1}{\sqrt{\text{MSE}/S_{xx}}}$. Elevamos al cuadrado:

$$t^2 = \frac{\hat{\beta}_1^2}{\text{MSE}/S_{xx}} = \frac{\hat{\beta}_1^2 S_{xx}}{\text{MSE}}. \quad (114)$$

Como $\text{SSR} = \hat{\beta}_1^2 S_{xx}$ y los grados de libertad de la regresión en regresión simple son 1 ($\text{MSR} = \text{SSR}/1$):

$$t^2 = \frac{\text{SSR}}{\text{MSE}} = \frac{\text{MSR}}{\text{MSE}} = F. \quad (115)$$

Puesto que $t_{n-2}^2 \equiv F_{1,n-2}$, ambos contrastes proporcionan **el mismo p -valor**.

1.8 Inferencia predictiva: respuesta media vs. nueva observación

Fijamos un punto predictivo x_0 . La estimación puntual sobre la recta es:

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 = (\bar{Y} - \hat{\beta}_1 \bar{x}) + \hat{\beta}_1 x_0 = \bar{Y} + \hat{\beta}_1 (x_0 - \bar{x}). \quad (116)$$

Deducción rigurosa de los intervalos de confianza y predicción

Paso 1: Demostración de $\text{Cov}(\bar{Y}, \hat{\beta}_1) = 0$:

$$\text{Cov}(\bar{Y}, \hat{\beta}_1) = \text{Cov}\left(\sum_{i=1}^n \frac{1}{n} Y_i, \sum_{j=1}^n k_j Y_j\right) = \sum_{i=1}^n \frac{k_i}{n} \text{Var}(Y_i) \quad (117)$$

$$= \frac{\sigma^2}{n} \sum_{i=1}^n k_i = \frac{\sigma^2}{n} \cdot \sum_{i=1}^n k_i = 0. \quad (118)$$

Paso 2: Varianza de la respuesta media $\mathbb{E}[Y | x_0]$: Como $\text{Cov}(\bar{Y}, \hat{\beta}_1) = 0$, la varianza de la suma es la suma de las varianzas:

$$\text{Var}(\hat{y}_0) = \text{Var}(\bar{Y}) + (x_0 - \bar{x})^2 \text{Var}(\hat{\beta}_1) \quad (119)$$

$$= \frac{\sigma^2}{n} + (x_0 - \bar{x})^2 \frac{\sigma^2}{S_{xx}} = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]. \quad (120)$$

El intervalo de confianza al $(1 - \alpha)100\%$ para la media poblacional es:

$$\text{IC}_{1-\alpha}(\mathbb{E}[Y | x_0]) = \hat{y}_0 \pm t_{\alpha/2, n-2} \sqrt{\text{MSE} \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}. \quad (121)$$

Paso 3: Varianza del error de predicción individual ($e_{\text{pred}} = Y_0 - \hat{y}_0$): Para un nuevo individuo independiente $Y_0 = \beta_0 + \beta_1 x_0 + \varepsilon_0$ con $\varepsilon_0 \sim \mathcal{N}(0, \sigma^2)$:

$$\text{Var}(e_{\text{pred}}) = \text{Var}(Y_0 - \hat{y}_0) = \text{Var}(Y_0) + \text{Var}(\hat{y}_0) \quad (\text{por independencia}) \quad (122)$$

$$= \sigma^2 + \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]. \quad (123)$$

El intervalo de predicción individual al $(1 - \alpha)100\%$ resulta:

$$\text{IP}_{1-\alpha}(Y_0) = \hat{y}_0 \pm t_{\alpha/2, n-2} \sqrt{\text{MSE} \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}. \quad (124)$$

Fundamento Conceptual & Geometría: Geometría de las bandas hiperbólicas

- Ambos intervalos adoptan una silueta hiperbólica con su cuello de máxima precisión exactamente en la media muestral $x_0 = \bar{x}$.
- Al alejarnos de $\bar{x}$, el término cuadrático $(x_0 - \bar{x})^2$ se incrementa con rapidez, ensanchando la incertidumbre e ilustrando analíticamente el **riesgo de extrapolación**.
- Aunque el tamaño muestral tienda a infinito ($n \rightarrow \infty$), el intervalo de predicción individual **nunca se reduce a cero** debido a la presencia ineludible del término $+1$, asociado a la variabilidad aleatoria inherente de la propia naturaleza del individuo (σ^2).

1.9 Diagnóstico e influencia: matriz H , Sherman-Morrison, Cook y DFFITS

Derivación completa del apalancamiento, Sherman-Morrison, Cook y DFFITS

Paso 1: Elementos diagonales de la matriz de proyección (h_{ii}): Escribimos la predicción $\hat{y}_i$ como combinación lineal de las observaciones:

$$\hat{y}_i = \bar{y} + \hat{\beta}_1(x_i - \bar{x}) = \frac{1}{n} \sum_{j=1}^n y_j + (x_i - \bar{x}) \sum_{j=1}^n \left(\frac{x_j - \bar{x}}{S_{xx}} \right) y_j \quad (125)$$

$$= \sum_{j=1}^n \left[\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}} \right] y_j = \sum_{j=1}^n h_{ij} y_j. \quad (126)$$

Por tanto, el apalancamiento (*leverage*) es el término diagonal:

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}. \quad (127)$$

La traza de la matriz sombrero suma exactamente los grados de libertad del modelo:

$$\sum_{i=1}^n h_{ii} = \sum_{i=1}^n \left[\frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}} \right] = n \cdot \frac{1}{n} + \frac{S_{xx}}{S_{xx}} = 1 + 1 = 2. \quad (128)$$

Paso 2: Deducción analítica de la varianza del residuo e_i : Como $e_i = (1 - h_{ii})y_i - \sum_{j \neq i} h_{ij} y_j$, y por la idempotencia de $\mathbf{H}$ se cumple $\sum_{j=1}^n h_{ij}^2 = h_{ii}$:

$$\text{Var}(e_i) = (1 - h_{ii})^2 \text{Var}(y_i) + \sum_{j \neq i} h_{ij}^2 \text{Var}(y_j) = \sigma^2 \left[(1 - h_{ii})^2 + \sum_{j \neq i} h_{ij}^2 \right] \quad (129)$$

$$= \sigma^2 [1 - 2h_{ii} + h_{ii}^2 + (h_{ii} - h_{ii}^2)] = \sigma^2(1 - h_{ii}). \quad (130)$$

Esto fundamenta la necesidad de definir los residuos estandarizados internamente:

$$r_i = \frac{e_i}{\sqrt{\text{MSE}(1 - h_{ii})}}. \quad (131)$$

Paso 3: Deducción analítica completa mediante el Lema de Sherman-Morrison: Al retirar la observación (x_i, y_i) , la matriz del sistema sin la fila i es:

$$\mathbf{X}_{(i)}^T \mathbf{X}_{(i)} = \mathbf{X}^T \mathbf{X} - x_i x_i^T. \quad (132)$$

Por el Lema de Sherman-Morrison para inversión de matrices perturbadas por rango uno:

$$(\mathbf{A} - uv^T)^{-1} = \mathbf{A}^{-1} + \frac{\mathbf{A}^{-1}uv^T\mathbf{A}^{-1}}{1 - v^T\mathbf{A}^{-1}u}. \quad (133)$$

Haciendo $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ y $u = v = x_i$, recordando que el leverage es el escalar $h_{ii} = x_i^T (\mathbf{X}^T \mathbf{X})^{-1} x_i$:

$$(\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1} = (\mathbf{X}^T \mathbf{X})^{-1} + \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i x_i^T (\mathbf{X}^T \mathbf{X})^{-1}}{1 - h_{ii}}. \quad (134)$$

El vector de regresión omitiendo la observación i se define como:

$$\hat{\beta}_{(i)} = (\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1} \mathbf{X}_{(i)}^T y_{(i)}. \quad (135)$$

Dado que $\mathbf{X}_{(i)}^T y_{(i)} = \mathbf{X}^T y - x_i y_i$, sustituimos la inversa (134):

$$\hat{\beta}_{(i)} = \left[(\mathbf{X}^T \mathbf{X})^{-1} + \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i x_i^T (\mathbf{X}^T \mathbf{X})^{-1}}{1 - h_{ii}} \right] (\mathbf{X}^T y - x_i y_i). \quad (136)$$

Distribuimos el producto de los dos corchetes término a término:

$$\hat{\beta}_{(i)} = \underbrace{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y}_{=\hat{\beta}} - (\mathbf{X}^T \mathbf{X})^{-1} x_i y_i \quad (137)$$

$$+ \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i x_i^T \overbrace{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y}^{=\hat{\beta}}}{1 - h_{ii}} - \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i x_i^T \overbrace{(\mathbf{X}^T \mathbf{X})^{-1} x_i y_i}^{=h_{ii}}}{1 - h_{ii}} \quad (138)$$

$$= \hat{\beta} - (\mathbf{X}^T \mathbf{X})^{-1} x_i y_i + \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i (x_i^T \hat{\beta})}{1 - h_{ii}} - \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i h_{ii} y_i}{1 - h_{ii}}. \quad (139)$$

Como la predicción para el punto i es el escalar $\hat{y}_i = x_i^T \hat{\beta}$, sacamos factor común del vector $(\mathbf{X}^T \mathbf{X})^{-1} x_i$ sobre el denominador común $(1 - h_{ii})$:

$$\hat{\beta}_{(i)} = \hat{\beta} - \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i}{1 - h_{ii}} [y_i(1 - h_{ii}) - \hat{y}_i + h_{ii} y_i] \quad (140)$$

$$= \hat{\beta} - \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i}{1 - h_{ii}} [y_i - \cancel{y_i h_{ii}} - \hat{y}_i + \cancel{h_{ii} y_i}] \quad (141)$$

$$= \hat{\beta} - \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i (y_i - \hat{y}_i)}{1 - h_{ii}}. \quad (142)$$

Como el residuo ordinario es $e_i = y_i - \hat{y}_i$, restando $\hat{\beta}$ en ambos miembros:

$$\hat{\beta} - \hat{\beta}_{(i)} = \frac{(\mathbf{X}^T \mathbf{X})^{-1} x_i e_i}{1 - h_{ii}}. \quad (143)$$

Para obtener el cambio en la predicci3n de cualquier otra observaci3n j , multiplicamos por su vector fila x_j^T :

$$\hat{y}_j - \hat{y}_{j(i)} = x_j^T (\hat{\beta} - \hat{\beta}_{(i)}) \quad (144)$$

$$= \frac{x_j^T (\mathbf{X}^T \mathbf{X})^{-1} x_i e_i}{1 - h_{ii}}. \quad (145)$$

Reconociendo que $h_{ji} = x_j^T (\mathbf{X}^T \mathbf{X})^{-1} x_i$ es exactamente el elemento (j, i) de la matriz sombrero $\mathbf{H}$:

$$\hat{y}_j - \hat{y}_{j(i)} = \frac{h_{ji} e_i}{1 - h_{ii}}. \quad (146)$$

Paso 4: Descomposici3n Analítica de la Distancia de Cook (D_i): La distancia de Cook evalúa el impacto en todas las predicciones:

$$D_i = \frac{\sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(i)})^2}{2 \cdot \text{MSE}}. \quad (147)$$

Sustituyendo el desplazamiento deducido en el Paso 3:

$$D_i = \frac{1}{2 \cdot \text{MSE}} \sum_{j=1}^n \left(\frac{h_{ji} e_i}{1 - h_{ii}} \right)^2 = \frac{e_i^2}{2 \cdot \text{MSE} (1 - h_{ii})^2} \underbrace{\sum_{j=1}^n h_{ji}^2}_{=h_{ii}} \quad (148)$$

$$= \frac{1}{2} \cdot \left[\frac{e_i^2}{\text{MSE} (1 - h_{ii})} \right] \cdot \left(\frac{h_{ii}}{1 - h_{ii}} \right) = \frac{1}{2} r_i^2 \left(\frac{h_{ii}}{1 - h_{ii}} \right). \quad (149)$$

Paso 5: Deducci3n Analítica de DFFITS: DFFITS mide el cambio estandarizado en la propia predicci3n del punto i usando la varianza residual estimada sin dicha observaci3n ($\text{MSE}_{(i)}$):

$$\text{DFFITS}_i \equiv \frac{\hat{y}_i - \hat{y}_{i(i)}}{\text{SE}(\hat{y}_{i(i)})} = \frac{\frac{h_{ii} e_i}{1 - h_{ii}}}{\sqrt{\text{MSE}_{(i)} h_{ii}}}. \quad (150)$$

Reorganizando los t́rminos algebraicos:

$$\text{DFFITS}_i = \frac{h_{ii} e_i}{(1 - h_{ii}) \sqrt{\text{MSE}_{(i)}} \sqrt{h_{ii}}} = \frac{\sqrt{h_{ii}} \sqrt{h_{ii}} e_i}{(1 - h_{ii}) \sqrt{\text{MSE}_{(i)}} \sqrt{h_{ii}}} \quad (151)$$

$$= \left[\frac{e_i}{\sqrt{\text{MSE}_{(i)} (1 - h_{ii})}} \right] \sqrt{\frac{h_{ii}}{1 - h_{ii}}} = t_i^* \sqrt{\frac{h_{ii}}{1 - h_{ii}}} \quad (152)$$

donde t_i^* es el **residuo estudentizado externamente** (o jackknife).

Fundamento Conceptual & Geometría: Interpretación docente del diagnóstico

Tanto Cook como DFFITS descomponen la influencia de una observación en el producto de dos dimensiones ortogonales e independientes:

$$\text{Influencia} \propto \underbrace{\text{Outlier en } Y}_{\text{Residuo Estudentizado}} \times \underbrace{\text{Apalancamiento en } X}_{\text{Leverage Relativo}}. \quad (153)$$

- Un dato con un residuo inmenso en el centro de la nube ($h_{ii} \approx 1/n$) no alterará la pendiente.
- Un dato extremo en X que caiga sobre la recta ($e_i \approx 0$) reforzará el ajuste sin cambiar las predicciones.
- Únicamente aquellos puntos que combinen **gran residuo** con **alto apalancamiento** alterarán sustancialmente los parámetros estimados.

2. Tema 2: El modelo de regresión lineal múltiple

En el contexto de la regresión lineal múltiple, el modelo con k variables explicativas y n observaciones se expresa en notación matricial como:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (154)$$

donde $\mathbf{y}$ es el vector de dimensión $n \times 1$ de la variable dependiente, $\mathbf{X}$ es la matriz de diseño de dimensión $n \times (k + 1)$, $\boldsymbol{\beta}$ es el vector $(k + 1) \times 1$ de coeficientes poblacionales y $\boldsymbol{\varepsilon}$ es el vector $n \times 1$ de perturbaciones aleatorias. Asumimos los supuestos estándar: $\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ y $\text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$.

Derivación del estimador de mínimos cuadrados ordinarios (MCO) en forma matricial

Paso 1: Planteamiento de la Función Objetivo La suma de los residuos al cuadrado se expresa de forma matricial como el producto escalar del vector de errores consigo mismo:

$$\text{SSE}(\boldsymbol{\beta}) = \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \quad (155)$$

$$= \mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\boldsymbol{\beta} - (\mathbf{X}\boldsymbol{\beta})^T \mathbf{y} + (\mathbf{X}\boldsymbol{\beta})^T \mathbf{X}\boldsymbol{\beta} \quad (156)$$

Dado que el producto $\mathbf{y}^T \mathbf{X}\boldsymbol{\beta}$ es un escalar (dimensión 1×1), su valor es idéntico al de su traspuesta:

$$(\mathbf{y}^T \mathbf{X}\boldsymbol{\beta})^T = \boldsymbol{\beta}^T \mathbf{X}^T \mathbf{y}. \quad (157)$$

Agrupando ambos términos idénticos, la función de pérdida queda:

$$\text{SSE}(\boldsymbol{\beta}) = \mathbf{y}^T \mathbf{y} - 2\boldsymbol{\beta}^T \mathbf{X}^T \mathbf{y} + \boldsymbol{\beta}^T \mathbf{X}^T \mathbf{X}\boldsymbol{\beta}. \quad (158)$$

Paso 2: Condición de Primer Orden Derivamos la función escalar $\text{SSE}(\boldsymbol{\beta})$ con respecto al vector de parámetros $\boldsymbol{\beta}$, empleando cálculo matricial elemental:

$$\frac{\partial \text{SSE}(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\boldsymbol{\beta} = \mathbf{0}. \quad (159)$$

Paso 3: Despeje Algebraico del Estimador $\hat{\boldsymbol{\beta}}$ Dividiendo ambos lados por 2 y aislando el término con $\boldsymbol{\beta}$ obtenemos las denominadas **ecuaciones normales**:

$$\mathbf{X}^T \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^T \mathbf{y}. \quad (160)$$

Bajo la condición de que la matriz de diseño $\mathbf{X}$ posea rango completo por columnas (ausencia de multicolinealidad perfecta), la matriz cuadrada y simétrica $\mathbf{X}^T \mathbf{X}$ resulta invertible. Premultiplicando por su inversa $(\mathbf{X}^T \mathbf{X})^{-1}$:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}. \quad (161)$$

Paso 4: Condición de Segundo Orden (Hessiano) Calculamos la matriz de segundas derivadas parciales (Hessiana):

$$\frac{\partial^2 \text{SSE}(\boldsymbol{\beta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^T} = 2\mathbf{X}^T \mathbf{X}. \quad (162)$$

Como $\mathbf{X}$ tiene rango completo, $\mathbf{X}^T \mathbf{X}$ es una matriz **estrictamente definida positiva**, garantizando que la solución $\hat{\boldsymbol{\beta}}$ corresponde a un **mínimo global** de la suma de cuadrados residual.

2.1 Propiedades estadísticas de MCO en regresión múltiple

Demostración de insesgadez y matriz de varianzas-covarianzas

Paso 1: Demostración de Insesgadez ($\mathbb{E}[\hat{\beta}] = \beta$) Sustituimos la estructura real de los datos $\mathbf{y} = \mathbf{X}\beta + \varepsilon$ en la fórmula del estimador:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{X}\beta + \varepsilon) \quad (163)$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \beta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon \quad (164)$$

$$= \mathbf{I}\beta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon = \beta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon. \quad (165)$$

Asumiendo que los regresores $\mathbf{X}$ son fijos, aplicamos el operador esperanza matemática:

$$\mathbb{E}[\hat{\beta}] = \mathbb{E}[\beta] + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbb{E}[\varepsilon] = \beta. \quad (166)$$

Paso 2: Derivación de la Matriz de Varianzas-Covarianzas La matriz de covarianza de un vector aleatorio $\hat{\beta}$ se define como $\text{Var}(\hat{\beta}) = \mathbb{E}[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T]$. Del paso anterior sabemos que $\hat{\beta} - \beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon$. Sustituimos esto en la definición:

$$\text{Var}(\hat{\beta}) = \mathbb{E}\left[(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon ((\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon)^T\right] \quad (167)$$

$$= \mathbb{E}\left[(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon \varepsilon^T (\mathbf{X}^T)^T ((\mathbf{X}^T \mathbf{X})^{-1})^T\right]. \quad (168)$$

Como $(\mathbf{X}^T \mathbf{X})$ es una matriz simétrica, su inversa también lo es. Por lo tanto, $((\mathbf{X}^T \mathbf{X})^{-1})^T = (\mathbf{X}^T \mathbf{X})^{-1}$. Al ser $\mathbf{X}$ fija, podemos extraerla de la esperanza:

$$\text{Var}(\hat{\beta}) = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \underbrace{\mathbb{E}[\varepsilon \varepsilon^T]}_{=\text{Var}(\varepsilon) = \sigma^2 \mathbf{I}_n} \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \quad (169)$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\sigma^2 \mathbf{I}_n) \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \quad (170)$$

$$= \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \underbrace{\mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1}}_{=\mathbf{I}} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}. \quad (171)$$

Advertencia Metodológica: Estructura de las predicciones y ortogonalidad matricial

El ajuste del modelo conduce al vector de valores predichos:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\beta} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} = \mathbf{H}\mathbf{y}. \quad (172)$$

La **Matriz de Proyección** (o matriz Sombrero) $\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ posee dos propiedades vitales: es **simétrica** ($\mathbf{H}^T = \mathbf{H}$) e **idempotente** ($\mathbf{H}^2 = \mathbf{H}$). El vector de residuos estimados $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H})\mathbf{y}$ representa la proyección ortogonal de $\mathbf{y}$ sobre el complemento ortogonal del espacio generado por $\mathbf{X}$. Geométricamente, esto implica la ortogonalidad estricta entre predictores y residuos:

$$\mathbf{X}^T \mathbf{e} = \mathbf{X}^T (\mathbf{y} - \mathbf{X}\hat{\beta}) = \mathbf{X}^T \mathbf{y} - \mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} = \mathbf{X}^T \mathbf{y} - \mathbf{X}^T \mathbf{y} = \mathbf{0}. \quad (173)$$

2.2 Teorema de Gauss-Márkov y varianza mínima (BLUE)

Demostración de varianza mínima para regresión múltiple (Gauss-Márkov)

Paso 1: Construcción de un estimador lineal genérico Sea $\tilde{\beta} = \mathbf{C}\mathbf{y}$ un estimador alternativo de β que sea **lineal** en $\mathbf{y}$. Podemos expresar su matriz de pesos $\mathbf{C}$ como una desviación respecto a la matriz de MCO:

$$\mathbf{C} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T + \mathbf{D} \quad (174)$$

donde $\mathbf{D}$ es una matriz arbitraria de dimensión $(k+1) \times n$.

Paso 2: Imposición de la condición de insesgadez Para que $\tilde{\beta}$ sea insesgado, debe cumplirse que $\mathbb{E}[\tilde{\beta}] = \beta$ para cualquier β :

$$\mathbb{E}[\tilde{\beta}] = \mathbb{E}[\mathbf{C}\mathbf{y}] = \mathbf{C}\mathbb{E}[\mathbf{X}\beta + \varepsilon] = \mathbf{C}\mathbf{X}\beta. \quad (175)$$

Esto exige que $\mathbf{C}\mathbf{X} = \mathbf{I}$. Sustituyendo nuestra definición de $\mathbf{C}$:

$$\left((\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T + \mathbf{D} \right) \mathbf{X} = \mathbf{I} \implies \underbrace{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X}}_{=\mathbf{I}} + \mathbf{D}\mathbf{X} = \mathbf{I} \implies \mathbf{D}\mathbf{X} = \mathbf{0}. \quad (176)$$

Paso 3: Cálculo y comparación de varianzas La matriz de varianzas-covarianzas del nuevo estimador es:

$$\text{Var}(\tilde{\beta}) = \text{Var}(\mathbf{C}\mathbf{y}) = \mathbf{C} \text{Var}(\mathbf{y}) \mathbf{C}^T = \sigma^2 \mathbf{C} \mathbf{C}^T. \quad (177)$$

Desarrollamos el producto $\mathbf{C} \mathbf{C}^T$:

$$\mathbf{C} \mathbf{C}^T = \left((\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T + \mathbf{D} \right) \left(\mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} + \mathbf{D}^T \right) \quad (178)$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{D}^T + \mathbf{D} \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} + \mathbf{D} \mathbf{D}^T \quad (179)$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} + \mathbf{D} \mathbf{D}^T. \quad (180)$$

Multiplicando por σ^2 :

$$\text{Var}(\tilde{\beta}) = \underbrace{\sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}}_{=\text{Var}(\hat{\beta})} + \sigma^2 \mathbf{D} \mathbf{D}^T. \quad (181)$$

Dado que cualquier matriz de la forma $\mathbf{D} \mathbf{D}^T$ es **semidefinida positiva**, las varianzas en la diagonal principal de $\text{Var}(\tilde{\beta})$ son mayores o iguales a las de $\text{Var}(\hat{\beta})$. La igualdad solo se da si $\mathbf{D} = \mathbf{0}$, probando que MCO es el Mejor Estimador Lineal Insesgado (BLUE).

2.3 Insesgadez de la varianza residual matricial

Demostración de $\mathbb{E}[\text{SSE}] = (n - k - 1)\sigma^2$ mediante operador traza

Paso 1: Expresión matricial de los residuos y la matriz Hat Recordamos que $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y}$. Sabiendo que $\mathbf{y} = \mathbf{X}\beta + \varepsilon$ y que $\mathbf{H}\mathbf{X} = \mathbf{X}$:

$$\mathbf{e} = (\mathbf{I} - \mathbf{H})(\mathbf{X}\beta + \varepsilon) = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta + (\mathbf{I} - \mathbf{H})\varepsilon = (\mathbf{I} - \mathbf{H})\varepsilon. \quad (182)$$

La suma de residuos al cuadrado es un escalar, que es igual a su propia traza (tr):

$$\text{SSE} = \mathbf{e}^T \mathbf{e} = \text{tr}(\mathbf{e}^T \mathbf{e}). \quad (183)$$

Paso 2: Permutación ćclica de la traza Por la propiedad ćclica de la traza $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$:

$$\text{SSE} = \text{tr}(\boldsymbol{\varepsilon}^T(\mathbf{I} - \mathbf{H})^T(\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}) \quad (184)$$

$$= \text{tr}(\boldsymbol{\varepsilon}^T(\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}) \quad (\text{ya que } \mathbf{I} - \mathbf{H} \text{ es simétrica e idempotente}) \quad (185)$$

$$= \text{tr}((\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^T). \quad (186)$$

Paso 3: Esperanza matemática y dimensión del espacio Aplicamos el operador esperanza matemática. Como la traza es un operador lineal:

$$\mathbb{E}[\text{SSE}] = \mathbb{E}[\text{tr}((\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^T)] = \text{tr}((\mathbf{I} - \mathbf{H})\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^T]). \quad (187)$$

Sustituyendo $\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^T] = \sigma^2\mathbf{I}_n$:

$$\mathbb{E}[\text{SSE}] = \text{tr}((\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}_n) = \sigma^2 \text{tr}(\mathbf{I} - \mathbf{H}) = \sigma^2(\text{tr}(\mathbf{I}_n) - \text{tr}(\mathbf{H})). \quad (188)$$

La traza de la identidad $\mathbf{I}_n$ es n . La traza de $\mathbf{H}$ es:

$$\text{tr}(\mathbf{H}) = \text{tr}(\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T) = \text{tr}((\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{X}) = \text{tr}(\mathbf{I}_{k+1}) = k + 1. \quad (189)$$

Por tanto, concluimos:

$$\mathbb{E}[\text{SSE}] = \sigma^2(n - (k + 1)) = (n - k - 1)\sigma^2. \quad (190)$$

De aqú se deduce el estimador insesgado de la varianza residual:

$$\mathbb{E}\left[\frac{\text{SSE}}{n - k - 1}\right] = \sigma^2 \implies \hat{\sigma}^2 = \text{MSE} = \frac{\mathbf{e}^T\mathbf{e}}{n - k - 1}. \quad (191)$$